GUIA DE APRENDIZAJE #1

Resumen del tema Primer Trimestre

Johan sbleider escobar ortiz

Servicio Nacional de Aprendizaje (SENA)

Centro de Materiales y Ensayos

Técnico en Procesamiento de Datos para Modelos de Inteligencia Artificial

Ficha: [3533558]

Trimestre II

Ing. Nathalia Martinez Vargas

31 de octubre de 2026

Bogotá D.C.

Actividades:

ACTIVIDAD 1

Pregunta 1: Excel sin saber la moneda

Procesar la columna sin conocer la moneda puede llevar a:

- Si una venta de $1.000 son dólares y no pesos, la diferencia es de miles de veces, no se sabría el margen del dinero.
- sumar o promediar columnas con monedas mezcladas da totales que no representan nada real.
- presupuestos, inventarios o precios mal definidos, y reportes que pierden credibilidad ante directivos y clientes.
- si estos datos alimentan un modelo, aprenderá patrones falsos

Pregunta 2: Por que es tan importante el "Diccionario de datos"

Es el paso más importante ya que nos da el repositorio de todos los datos que haya en una base de datos.

- evita malinterpretar los datos ; justo en el caso de la NASA se pudo haber evitado si el diccionario de datos hubiera tenido claro que dijera : "libras-fuerza" se hubiera evitado el error
- se garantiza que cualquiera que use la base de datos entienda y maneje la base de la misma manera.

Pregunta 3: Primer trabajo sin metadatos:

La primera acción debería ser no calcular nada todavía y buscar el contexto de los datos.

- podríamos preguntar al responsable del manejo de datos de la empresa nos diga de donde proviene y cómo se recolectaron
- explorar las bases de datos y darles su significado .
- también podemos construir un borrador de diccionario de datos

Pregunta 4: Para qué tener una bigdata si falla la compresión estructural?:

- un error de comprensión se multiplica con el volumen de datos así que no importa la big data que tengas.
- La NASA tiene ingenieros y tecnología de sobra y aun así hubo un error de comprensión.

ACTIVIDAD 2:

FASE 1: Preguntas de negocios con la carga del data set:

Primera: **¿Qué segmento de clientes aporta más valor?**

Compara consumidor, corporativo en casa por ventas, ganancia y frecuencia de compra. Usa Segmento, Cliente, Ventas y Ganancia;se usaría para las decisiones posibles: enfocar el marketing.

Segunda:**¿Qué regiones o estados son más rentables y cuáles tienen mejor desempeño que otros?**

Sirve para ver dónde invertir o reforzar la operación. Usa Región, Estado, Ventas y Ganancia.

Tercera:**¿Los descuentos están afectando la rentabilidad?**

Compara el nivel de descuento con la ganancia por pedido y busca a partir de qué porcentaje empiezan las pérdidas. Usa Descuento, Ventas y Ganancia. Decisión posible: poner un tope a los descuentos.

FASE 2: DICCIONARIO DE DATOS DE DATASET:datossupermercado.csv

#	Campo	Tipo	Descripción	Ejemplo / valores
1	Row ID	Entero	Identificador único de cada fila	1, 2, 3
2	Order ID	Texto	Identificador del pedido. Se repite si el pedido tiene varios productos	CA-2016-152156
3	Order Date	Fecha	Fecha en que se hizo el pedido	11/8/2016
4	Ship Date	Fecha	Fecha en que se envió el pedido	11/11/2016
5	Ship Mode	Texto (categórica)	Modalidad de envío	Standard Class, Second Class, First Class, Same Day
6	Customer ID	Texto	Identificador único del cliente	CG-12520
7	Customer Name	Texto	Nombre del cliente	Claire Gute
8	Segment	Texto (categórica)	Tipo de cliente	Consumer, Corporate, Home Office
9	Country	Texto	País de la venta	United States
10	City	Texto	Ciudad de destino	Henderson
11	State	Texto	Estado de destino	Kentucky
12	Postal Code	Entero	Código postal de destino	42420
13	Region	Texto (categórica)	Región geográfica	West, East, Central, South
14	Product ID	Texto	Identificador único del producto	FUR-BO-10001798
15	Category	Texto (categórica)	Categoría principal del producto	Furniture, Office Supplies, Technology
16	Sub-Category	Texto (categórica)	Subcategoría del producto	Chairs, Phones, Binders, etc.
17	Product Name	Texto	Nombre del producto	Bush Somerset Collection Bookcase
18	Sales	Decimal	Valor de la venta en dólares (USD)	261.96
19	Quantity	Entero	Unidades vendidas	2
20	Discount	Decimal	Descuento aplicado, de 0 a 1 (0.2 = 20 %)	0, 0.2, 0.7

#	Campo	Tipo	Descripción	Ejemplo / valores
21	Profit	Decimal	Ganancia de la fila en USD. Puede ser negativa si hubo pérdida	41.91, -383.03

FASE 3:

PREGUNTAS DE NEGOCIO SQL REPORT

- Primera: **¿Qué segmento de clientes aporta más valor?:**

Sentencia SQL utilizada:

```
SELECT Segment,
      COUNT(DISTINCT "Customer ID") AS clientes,
      ROUND(SUM(Sales), 2) AS ventas,
      ROUND(SUM(Profit), 2) AS utilidad,
      ROUND(100.0 * SUM(Profit) / SUM(Sales), 2) AS margen_pct,
      ROUND(SUM(Profit) / COUNT(DISTINCT "Customer ID"), 2)
        AS utilidad_por_cliente
FROM datossupermercado
GROUP BY Segment
ORDER BY ventas DESC;
```

El segmento consumer (consumidor) es el que genera mayor volumen absoluto, aportando la mayor cantidad de ventas con más de un millón de dólares y utilidades de ciento treinta y cuatro mil dólares. sin embargo el segmento home office(oficina en casa) es el más eficiente y rentable por cliente, genera hasta el 14% de la utilidad a diferencia del consumer que es del 11,55%

	Segment	clientes	ventas	utilidad	margen_pct	utilidad_por_cliente
0	Consumer	409	1161401.34	134119.21	11.55	327.92
1	Corporate	236	706146.37	91979.13	13.03	389.74
2	Home Office	148	429653.15	60298.68	14.03	407.42

- Segunda:**¿Qué regiones o estados son más rentables y cuáles tienen mejor desempeño que otros?**

Sentencia SQL utilizada:

```
-- Por región
SELECT Region,
```

```
    ROUND(SUM(Sales), 2) AS ventas,
    ROUND(SUM(Profit), 2) AS utilidad,
    ROUND(100.0 * SUM(Profit) / SUM(Sales), 2) AS margen_pct,
    ROUND(AVG(Discount), 3) AS desc_prom
FROM datossupermercado
GROUP BY Region
ORDER BY utilidad DESC;

-- Por estado: mismas columnas, agrupando por State
-- (10 más rentables: ORDER BY utilidad DESC LIMIT 10;
--  10 con pérdidas:  ORDER BY utilidad ASC  LIMIT 10;)
SELECT State,
    ROUND(SUM(Sales), 2) AS ventas,
    ROUND(SUM(Profit), 2) AS utilidad,
    ROUND(100.0 * SUM(Profit) / SUM(Sales), 2) AS margen_pct,
    ROUND(AVG(Discount), 3) AS desc_prom
FROM datossupermercado
GROUP BY State
ORDER BY utilidad DESC
LIMIT 10;
```

La región West(oeste) lidera la rentabilidad y las ventas en estados como california y new york

y la región central con estados como illinois y pennsylvania suelen registrar pérdidas post sun márgenes

	Region	ventas	utilidad	margen_pct	desc_prom
0	West	725457.82	108418.45	14.94	0.109
1	East	678781.24	91522.78	13.48	0.145
2	South	391721.91	46749.43	11.93	0.147
3	Central	501239.89	39706.36	7.92	0.240

	State	ventas	utilidad	margen_pct	desc_prom
0	California	457687.63	76381.39	16.69	0.073
1	New York	310876.27	74038.55	23.82	0.055
2	Washington	138641.27	33402.65	24.09	0.064
3	Michigan	76269.61	24463.19	32.07	0.007
4	Virginia	70636.72	18597.95	26.33	0.000
5	Indiana	53555.36	18382.94	34.33	0.000
6	Georgia	49095.84	16250.04	33.10	0.000
7	Kentucky	36591.75	11199.70	30.61	0.000
8	Minnesota	29863.15	10823.19	36.24	0.000
9	Delaware	27451.07	9977.37	36.35	0.006

	State	ventas	utilidad	margen_pct	desc_prom
0	Texas	170188.05	-25729.36	-15.12	0.370
1	Ohio	78258.14	-16971.38	-21.69	0.325
2	Pennsylvania	116511.91	-15559.96	-13.35	0.329
3	Illinois	80166.10	-12607.89	-15.73	0.390
4	North Carolina	55603.16	-7490.91	-13.47	0.284
5	Colorado	32108.12	-6527.86	-20.33	0.316
6	Tennessee	30661.87	-5341.69	-17.42	0.291
7	Arizona	35282.00	-3427.92	-9.72	0.304
8	Florida	89473.71	-3399.30	-3.80	0.299
9	Oregon	17431.15	-1190.47	-6.83	0.289

- Tercera:**¿Los descuentos están afectando la rentabilidad?:**

Sentencia SQL utilizada:

```
SELECT CASE
       WHEN Discount = 0    THEN '1. Sin descuento'
       WHEN Discount <= 0.2 THEN '2. 1%-20%'
       WHEN Discount <= 0.4 THEN '3. 21%-40%'
       ELSE '4. Más de 40%'
     END AS rango,
     COUNT(*) AS lineas,
     ROUND(SUM(Sales), 2) AS ventas,
     ROUND(SUM(Profit), 2) AS utilidad,
     ROUND(100.0 * SUM(Profit) / SUM(Sales), 2) AS margen_pct,
     ROUND(100.0 * SUM(CASE WHEN Profit < 0 THEN 1 ELSE 0 END)
          / COUNT(*), 1) AS pct_con_perdida
FROM datossupermercado
GROUP BY rango
ORDER BY rango;
```

Se ve que sin descuentos es super rentable a comparación de los descuentos de entre el 21% y el 40%

que ya se vuelven críticos,el margen cae hasta un 15%.

sin embargo los descuentos de entre el 1 y el 20% me deja un margen positivo de hasta un 11,91%

	rango	lineas	ventas	utilidad	margen_pct	pct_con_perdida
0	1. Sin descuento	4798	1087908.47	320987.60	29.51	0.0
1	2. 1%-20%	3803	846522.24	100785.47	11.91	13.8
2	3. 21%-40%	460	234137.90	-35817.47	-15.30	90.2
3	4. Más de 40%	933	128632.25	-99558.59	-77.40	100.0

Uso de Inteligencia Artificial

Para el desarrollo de esta guía se utilizaron las herramientas de inteligencia artificial Gemini y Claude, en aproximadamente un 30 % del trabajo total.